

# 模式识别

度量 Metric

信息论 Information Theory 简介

决策树 Decision tree

吴建鑫

南京大学计算机系 & 人工智能学院, 2020

# 目标

- ✓ 理解和掌握度量的基本知识
- ✓ ~~掌握~~ 常见的度量
- ✓ 掌握信息论的基本概念
- ✓ 掌握决策树的基本知识
  
- ✓ 提高目标
  - 进一步能通过独立阅读、了解distance metric learning
  - 进一步能通过独立阅读、了解ensemble of decision tree和random forest

# 度量

---

Metric

# 特征的表示和比较

✓ 两个重要的任务：

- 特征的表示：特征抽取后，如何表示为数学化或者计算机可以理解的数据形式？

- 到目前为止：所有数据均表示为一个连续的实数值的向量  $x \in \mathbb{R}^d$

- 特征的比较：比较两个点的相似性

- 在NN、线性分类器、SVM中到目前为止是用欧式距离
  - 在概率方法中，如高斯分布和KDE，也是欧式距离

✓ 对这些数据（实数向量、可以计算距离或相似程度），称为metric data

✓ 但是：还有很多其他类型的数据

# 更多的数据类型

- ✓ 标记数据 Nominal data
  - 如数据 1, 2, 3 分别表示苹果、梨和香蕉
  - 不是连续的实数值、也不可以比较大小（ $1 < 2$  代表苹果不如梨吗？）、不可以比较相似性
- ✓ 时间序列数据 time series data
  - 如一个序列(63, 64, 62)是单个样例，表示某人今天早中晚测量的体重；(61, 65)是第二天早晚的体重
  - 不是向量，测量次数不等，如何比较？
- ✓ ...
- ✓ 后续章节将针对不同数据的模式识别进行介绍

# 更多的度量

- ✓ 目前已用
  - 不相似程度或距离：欧式距离
  - 相似程度：内积或者RBF核
  - 两种紧密关联
- ✓ 但是，数据的不同特点要求使用不同的度量
- ✓ 那么，什么是度量metric？

# Metric

- ✓ 一个度量 $d$ 必须满足：对任意向量 $\mathbf{x}, \mathbf{y}, \mathbf{z}$ 
  - 非负nonnegative:  $d(\mathbf{x}, \mathbf{y}) \geq 0$
  - 自反:  $d(\mathbf{x}, \mathbf{y}) = 0$ 当且仅当 $\mathbf{x} = \mathbf{y}$
  - 对称symmetric:  $d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x})$
  - ~~三角不等式triangle inequality:~~  $d(\mathbf{x}, \mathbf{y}) + d(\mathbf{y}, \mathbf{z}) \geq d(\mathbf{x}, \mathbf{z})$
- ✓ 欧式距离满足这些条件吗？

$$d^2(x, y) = (x - y)^T \underline{\text{dig}}(x - y)$$

每一维权重

## 从欧式距离到度量学习

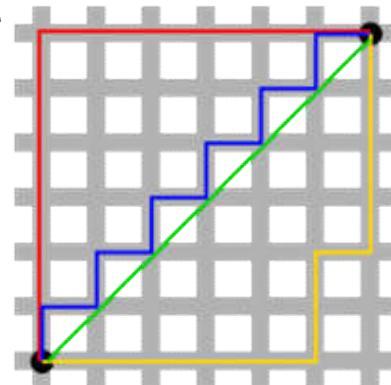
- ✓ Euclidean distance:  $d^2(x, y) = (x - y)^T (x - y)$  欧氏
- ✓ Mahalanobis distance:  $d^2(x, y) = (x - y)^T \Sigma^{-1} (x - y)$  马氏
  - $\Sigma$  是数据的协方差矩阵 (不一定对角, 非对角表示维与维不独立)
  - 练习: 若对数据进行白化操作, 则原空间中的马氏距离等价于白化变化以后新空间的欧式距离
- ✓ 进一步推广: 可以用一个半正定的矩阵  $A$  代替  $\Sigma^{-1}$ 
  - $d_A^2(x, y) = (x - y)^T A (x - y)$
  - $A$  半正定, 存在  $G$ , 使得  $A = G^T G$  ( $G$  不一定是对称)
  - 因此,  $d_A^2(x, y) = \|Gx - Gy\|_2^2$  (如  $A$  不正定, ?)
  - 那么, 如何设置  $A$  的值? 可以使用标记信息!
    - 进一步阅读: distance metric learning 度量学习

绝对值:  $(-0.3) \nearrow X$   
 $(0.3) \nearrow$  有效

# 固定形式的distance

✓ Minkowski distance:  $d_p(x, y) = (\sum_{i=1}^d |x_i - y_i|^p)^{\frac{1}{p}}$

- $p \geq 1$  时是 metric
- $p = 2$  时是欧式距离
- $p = 1$ :  $\sum_{i=1}^d |x_i - y_i|$ , 称为 Manhattan distance 曼哈顿距离, 或者 city block distance
- 若  $p < 1$ , 不是 metric (举例?)
  - 但是有时仍然可以用来比较两样例



图片来自英文Wiki



# Norm、distance、similarity

- ✓ 一个向量  $x$  的  $p$  norm (或者  $L_p$  norm) :

$$\|x\|_p = \left( \sum_{i=1}^d |x_i|^p \right)^{\frac{1}{p}}$$

- 限制条件:  $p \geq 1$ 
  - $\|x\|_\infty = \max(|x_1|, \dots, |x_d|)$   $\max(|X_1|, \dots, |X_d|)$
- ✓ 距离和长度的关系:  $d_p(x, y) = \|x - y\|_p$
- ✓ 从距离 (不相似度) 到相似度, 例如

$$\exp(-\gamma \|x - y\|_p)$$
$$\exp(-\gamma ||x-y||_p)$$

# 幂平均函数

✓ 幂平均 power mean (generalized mean) function

•  $M_p(x_1, \dots, x_n) = \left( \frac{1}{n} \sum_{i=1}^n x_i^p \right)^{\frac{1}{p}}$  要求  
 $x_i > 0$

• 对  $p$  在 整个实数轴上都有定义 (有些通过极限定义)

■  $M_{-\infty} = \min(x_1, \dots, x_n)$

■  $M_{-1}$  -- 调和平均 harmonic mean 已经用过

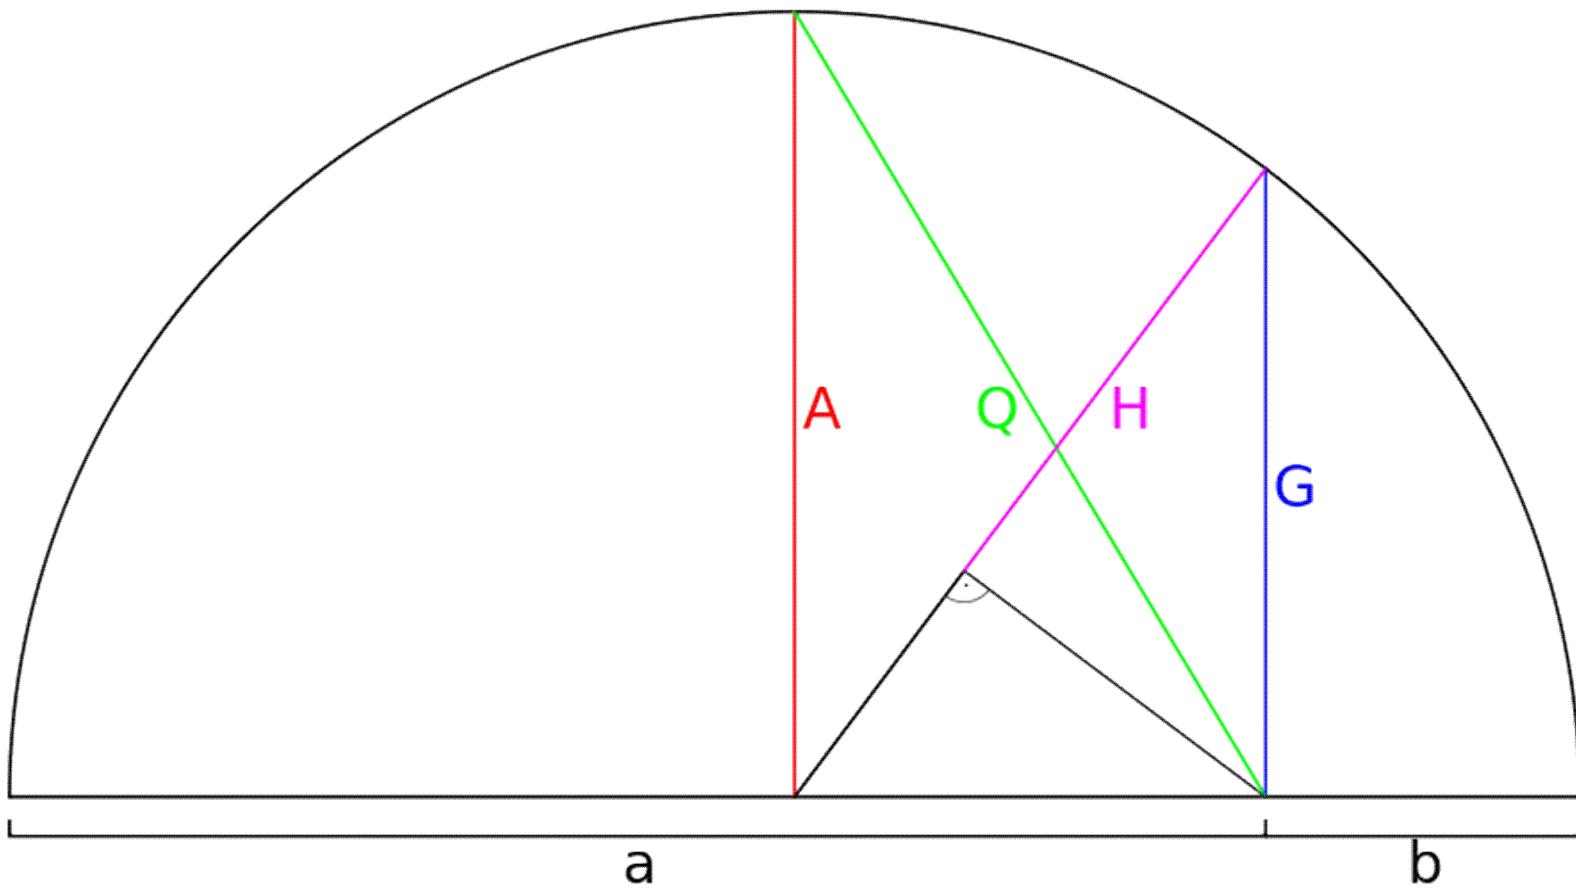
■  $M_0 = \sqrt[n]{x_1 x_2 \cdots x_n}$  -- 几何平均

■  $M_1$  -- 算术平均

■  $M_2$  -- root mean square

■  $M_\infty = \max(x_1, \dots, x_n)$

• 若  $p < q$ , 则  $M_p(x_1, \dots, x_n) \leq M_q(x_1, \dots, x_n)$



若考虑两个实数 $a$ 和 $b$ ，  
则 $M_p(a, b)$ 可以视为比较他们的相似程度

# 幂平均核 power mean kernel

$$M_p(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^d M_p(x_i, y_i)$$

- ✓ 当  $p \leq 0$  时，以上函数为 Mercer 核
- ✓ 属于加性核 additive kernel
  - $p = 0, \sqrt{x_i y_i}$  -- Hellinger's Kernel
  - $p = -1, \frac{2x_i y_i}{x_i + y_i}$  --  $\chi^2$  核
  - $p = -\infty, \min(x_i, y_i)$  -- histogram intersection 核  
(直方图相交?)
- ✓ 当特征是直方图时，加性核效果极佳
- ✓ 进一步阅读：关于加性核

# Nominal data

---

标记数据

# 标记数据的比较

- ✓ 标记数据 Nominal data
  - 如数据 1, 2, 3 分别表示苹果、梨和香蕉，怎么比较？
- ✓ 基本思想：相同则为1，否则为0，即两个标记数据  $x$  和  $y$  的相似度为  $\mathbb{I}(x = y)$

## ✓ 度量化 指示函数

- 设标记数据可以取  $m$  个不同的值，标记为  $\{1, 2, \dots, m\}$
- 将标记数据  $x = i$  转换成一个向量  $\begin{pmatrix} \mathbf{0}_{i-1} & 1 & \mathbf{0}_{d-i} \\ < i & i & > i \end{pmatrix}$
- 假设  $x, y$  转换为  $\mathbf{x}, \mathbf{y}$ ，那么  $\mathbb{I}(x = y) = ? \quad \mathbf{x}^T \mathbf{y}$
- SVM 即可用该方法处理标记数据

转换为向量的优点：  
① 内积易优化，可视为 metric data  
② 适用于 SVM

缺点：维度变高，但稀疏向量内积计算开销小

# 从度量化到直方图

✓ 可以看成，度量化的过程是将一个标记数据转化成一个所有可能取值的直方图

- 一个直方图histogram是对一个集合中元素的计数
- 若 $x = i$ , 其度量化的结果 $x$ 为 $m$ 个bin的直方图
- 第*i*个bin值为1, 表示有一个样例取值为*i*
- 其余所有bin为0, 表示没有任何样例取这些值
- 是一个有效的对集合 $\{x\}$ 的直方图吗？

✓ 那么，假设有两组数据，直方图分别为 $x$ 和 $y$

- 应该怎么计算其相似性？两个直方图的相似性
- $\min(x_i, y_i) / \sum \min(x_i, y_i)$

# 信息论（极）简介

---

A (very) brief introduction to the information theory

# 从直方图到概率分布

- ✓ 在非参数估计中，我们怎么估计一个分布？
  - 最早从直方图开始
  
- ✓ 那么我们怎么比较两个分布呢？
  - 假设 $p$ 和 $q$ 是两个离散分布，那么HJK可以用吗？怎么用？
  - 如果是连续分布呢？有没有理论上完备的方法？
  - 信息论！Information theory

传达一段信息的最小串长度：信息量

# 信息 information

- ✓ 描述一个随机变量需要多少信息？

- 假设用bit来作为信息的单位

信息量=0——若离散变量满足 $P(x = 2) = 1, P(x \neq 2) = 0$ ?

- 若离散变量是{1, 2, 3, 4}上的均匀uniform分布？

- ✓ 熵entropy  $\sum_i P_i \log_2 P_i$  需要2个bit

H非负 •  $H = -\sum_{i=1}^m P_i \log_2 P_i$  ( $m$ 个离散可能取值，各为 $P_i$ )

- 如果 $P_i = 0$ ？

■ 定义 $0 \log_2 0 = 0!$ ，因为 $\lim_{x \rightarrow 0} x \log_2 x = 0$  定义 $0 \log_2 0 = 0$

- 什么时候最大？什么时候最小？

■ 均匀分布的时候最大， $\log_2 m$

■ 单点分布最小，0

# Differential entropy

✓ 如果分布是连续的?  $-\int p(x) \ln(p(x)) dx$

$h(x)$  可以 < 0  $h(x) = -\int p(x) \ln(p(x)) dx$

- 自然对数, 单位是 nat (奈特)  $\frac{1}{2} \ln(2\pi e \sigma^2)$  若  $\sigma^2 < \frac{1}{2\pi e}$ , 则  $h(x) < 0$

$h(x)$  与  $\mu$  无关 • 若  $X \sim N(\mu, \sigma^2)$ , 则  $h(X) = \frac{1}{2} \ln(2\pi e \sigma^2)$  nats

$h(x)$  与 pdf 形状

有关, 是不确定性的度量

在所有 **均值和方差固定的连续分布** 中, 高斯分布具有最大的熵

- 或者说, 不确定性 uncertainty 最大

## Joint, conditional entropy

✓  $H(X, Y) = - \sum_x \sum_y P(x, y) \frac{\log_2 P(x, y)}{\log_2 P(x, y)}$  (X, Y)-一起考慮的信  
息量

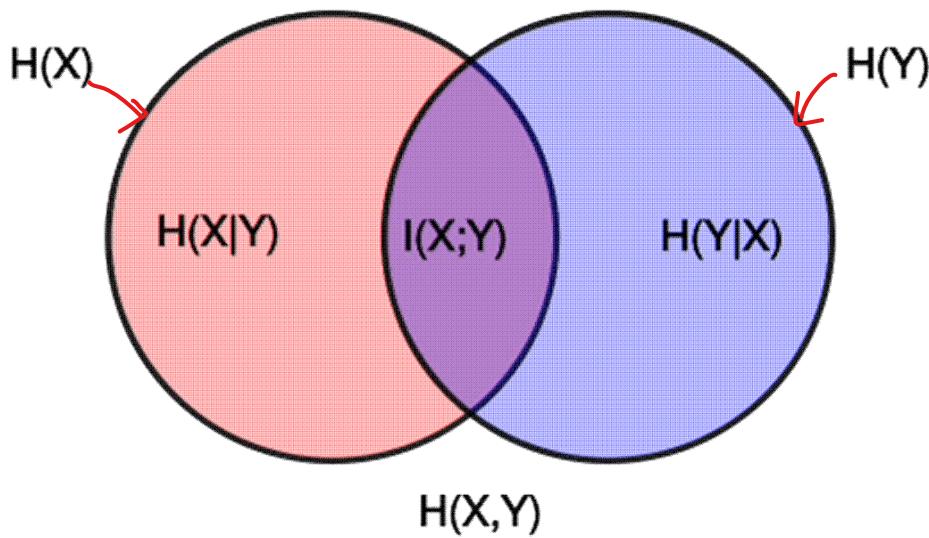
✓  $h(X|Y) = - \int p(x, y) \ln p(x|y) dx dy$  \ln p(x|y)

✓  $H(X|Y) = \sum_y p(y) H(X|Y=y) =$   
 $\sum_{x,y} P(x, y) \log_2 \frac{P(y)}{P(x, y)} = - \sum_{x,y} P(x, y) \log_2 \frac{P(x, y)}{P(y)}$

✓  $h(X|Y) = - \int p(x, y) \ln p(x|y) dx dy =$   
 $- \int p(x, y) \ln \frac{p(x, y)}{p(y)} dx dy$

已知Y, X还有多少信息量

# 各种熵之间的关系



用“描述长度”来记忆

- $H(X,Y) = H(Y) + H(X|Y)$
- $H(X,Y) = H(X) + H(Y|X)$
- $H(X|Y) \leq H(X)$
- $H(Y|X) \leq H(Y)$

问题

- $H(X|Y) = H(Y|X)$ ? 不一定
- 那么  $I(X;Y)$  代表什么?

X,Y的共同信息

图片来自英文Wiki

# 互信息 Mutual information

- ✓ 如果  $X$  和  $Y$  互相独立，即  $p(x, y) = p(x)p(y)$ ，或者  $P(x, y) = P(x)P(y)$

- 上面的图应该画什么？

- $I(X; Y)$  表示  $X$  和  $Y$  共同的那部分信息

$$I(X; Y) = H(X) - H(X|Y) = \sum_{x,y} p(x, y) \log_2 \frac{p(x, y)}{\underbrace{p(x)p(y)}_{X, Y \text{ 也独立}}}$$

$$= H(Y) - H(Y|X)$$

- ✓  $I(X; Y) = I(Y; X)$ ?

- ✓ 可以粗略的看成相似程度或者相关程度

$$I(X; Y) = \begin{cases} 0, & X \text{ 对预测 } Y \text{ 无用} \\ \text{非 } 0, & X \text{ 对预测 } Y \text{ 很有用} \end{cases}$$

# KL散度

- ✓ Kullback-Leibler divergence: 两个离散分布  $P$  和  $Q$

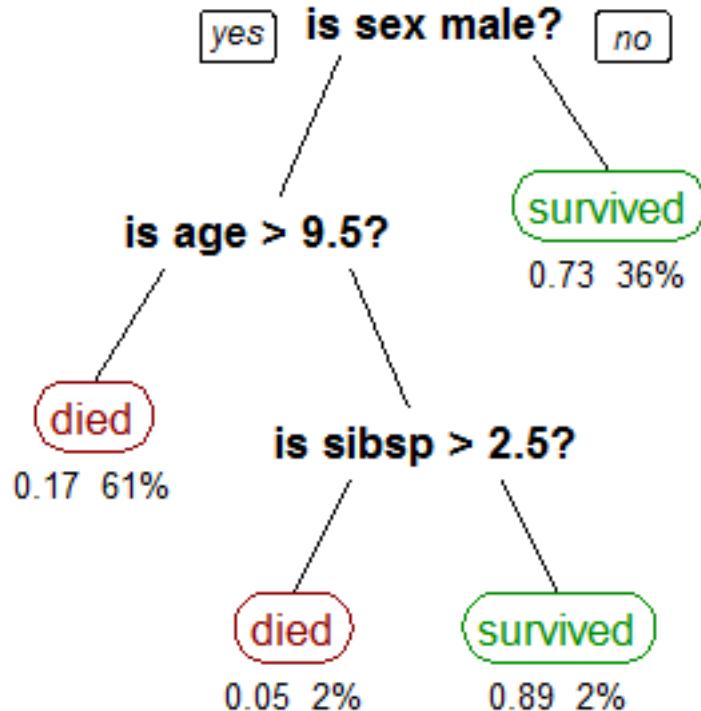
$$D_{KL}(P \parallel Q) = \sum_i P_i \log_2 \frac{P_i}{Q_i}$$

- $D_{KL}(P \parallel Q) \geq 0$ , 等号当且仅当  $\forall i, P_i = Q_i$  时成立
- $I(X; Y) = D_{KL}(p(x, y) \parallel p(x)p(y))$
- 可以粗略看成“距离”, 但不是 metric
- 但是, KL散度对称吗? 不对称

实用  
决策树 / 简单  
回归  
...

Decision Tree

# Titanic survivors



- 该判断模型是树tree
- 每次根据一个数据（称为属性）分成若干部分
- 当不可再分时（叶节点），给出一个决策decision
  - 通常输出的决策是标记数据
  - 可以输出一个概率分布

配偶 兄弟姐妹

图片来自英文Wiki。Sibsp: number of spouses or siblings aboard

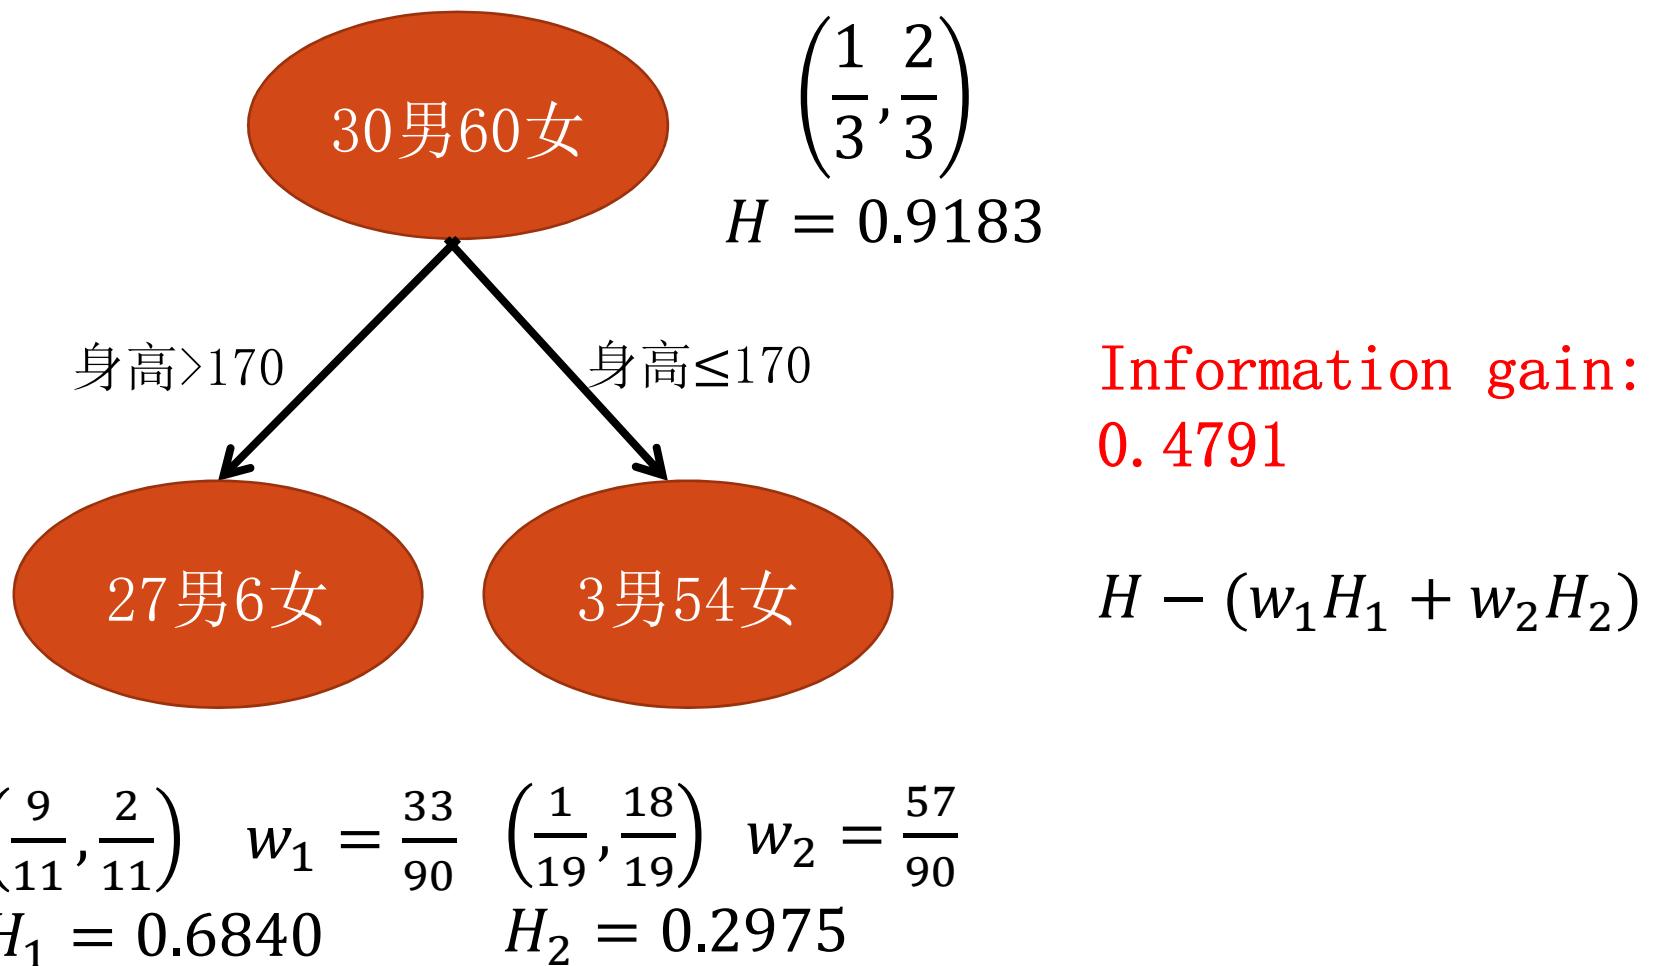
# 那么，选哪个属性来分？

①怎么分  
②什么时候不分  
③怎么预测

- ✓ 问题的输出是标记数据，有 $m$ 个可能的值
- ✓ 如果当前节点一共包含 $n$ 个样例，记为集合 $T$
- ✓ 其对应样例的ground truth输出是集合 $y_T$
- ✓ 计算 $H(y_T)$  - 当前节点的不纯度 impurity
- ✓ 对每一个属性 $j$  (循环)
  - 其不同值将当前节点数据分为若干子集 $T_1, T_2, \dots$
  - 计算每个子集的entropy:  $H(y_{T_k})$  和比例 $w_k$  条件熵
  - 计算按此属性分开后的平均不纯度  $\sum_k w_k H(y_{T_k})$
  - Information gain信息增益:  $H(y_T) - \sum_k w_k H(y_{T_k})$
- ✓ 选择信息增益最大的那个属性

递归执行

## 示意图：判断性别



# 其他问题

- ✓ 信息增益是一种选择的方法，其他方法很多
  - 在数据挖掘课程中讲述，这里不讲
- ✓ 但是，可以想象可能存在的其余问题？
  - 分到什么程度为止？即，什么时候不再分了？
  - 如果某属性有100个可能的取值，分100个嘛？
  - 其中有连续属性怎么办？
  - 计算和存储复杂度是多少？
  - ...

# 进一步的阅读

✓ 如果对本章的内容感兴趣，可以参考如下文献

- Distance metric learning: [http://www.cse.ohio-state.edu/~kulis/pubs/fml\\_metric\\_learning.pdf](http://www.cse.ohio-state.edu/~kulis/pubs/fml_metric_learning.pdf)
  - 加性核：[W5] in  
<http://cs.nju.edu.cn/wujx/publication.htm>
  - 信息论：Elements of Information Theory, 2<sup>nd</sup> edition,  
<http://www.amazon.com/Elements-Information-Theory-Telecommunications-Processing/dp/0471062596>
  - Information Theory, Inference, and Learning Algorithms, by David MacKay,  
<http://www.inference.phy.cam.ac.uk/itila/book.html>
- ✓ Random forest: [http://stat-www.berkeley.edu/users/breiman/RandomForests/cc\\_home.htm](http://stat-www.berkeley.edu/users/breiman/RandomForests/cc_home.htm)